KHALID EL GAMOUS

Ingénieur Data Senior

+212 611-458341 | khalidelgamous1@gmail.com | LinkedIn | GitHub | Kénitra, Maroc

À PROPOS

Ingénieur Data orienté résultats, expert dans la conception d'architectures d'acquisition de données scalables et de pipelines de traitement distribués. Spécialiste de l'automatisation web complexe, de l'ingénierie anti-détection et de l'orchestration ETL/ELT. Maîtrise confirmée des architectures Medallion (Lakehouse) et de l'intégration de modèles IA/NLP locaux pour l'enrichissement des données. Capacité prouvée à déployer des solutions conteneurisées robustes transformant des données brutes et non structurées en intelligence stratégique.

EXPÉRIENCES PROFESSIONNELLES

Lakehouse de Données & Automatisation d'Envoi d'E-mails Générés par IA — 2024-11 — 2025-05

ADSGLORY / Tangier

Architecture d'un système de bout en bout pour l'ingestion de données, mise en œuvre d'un système complet d'envoi d'e-mails automatisés, avec génération de contenu via intelligence artificielle et orchestration distribuée.

- Conception d'un pipeline d'ingestion multi-étapes pour extraire des données non structurées (Gmail/RSS) vers une couche de stockage Delta Lake.
- Mise en œuvre d'un prétraitement NLP distribué (lemmatisation et NER) et génération de contenu par un LLM (Text, HTML), et mise à jour des données enrichies.
- Ingénierie d'un système de diffusion à grande échelle utilisant Celery et Playwright, simulant le comportement humain pour contourner les filtres automatisés.
- Déploiement de tâches de monitoring pour garantir la santé du pipeline, la fiabilité de la livraison et la gestion des erreurs sous Docker.

Technologies: Apache Spark, gRPC, Celery, spaCy, Playwright, Ansible, Django REST Framework, React, PostgreSQL, Docker.

Détection de Formulaires Web pour le Warm-up d'E-mails par ML — 2024-07 — 2024-11

ADSGLORY / Tangier

Développement d'un système d'analyse de sites web pour identifier automatiquement les formulaires utiles au warm-up d'e-mails (ex. : newsletter, mot de passe oublié, contact).

- Extraction automatisée de formulaires HTML et de sélecteurs CSS pour constituer un dataset propriétaire d'interactions.
- Entraînement d'un modèle de Machine Learning supervisé (TF-IDF + Multinomial Naive Bayes) pour classifier les types de formulaires avec précision.
- Utilisation de MLflow pour le suivi des expériences et le versioning des modèles, garantissant la reproductibilité des résultats.

- Exposition des prédictions via une API REST pour une intégration fluide avec les outils d'automatisation avals.

Technologies: Python (Scikit-learn), MLflow, Django REST Framework, Docker, PostgreSQL.

Pipeline Distribué d'Agrégation de Données Multi-Sources 2023-10 — 2024-01

ADSGLORY / Tangier

Conception d'un pipeline ETL à haut débit pour l'agrégation et la validation de données issues de MongoDB, Elasticsearch et fichiers plats.

- Optimisation de la logique d'insertion pour MongoDB et Elasticsearch afin de gérer l'agrégation d'enregistrements uniques à grande échelle.
- Mise en œuvre du traitement parallèle pour une extraction efficace des données et un reporting consolidé.
- Développement de couches d'automatisation du nettoyage et de la validation pour garantir la qualité des données avant consommation.

Technologies: Apache Spark, MongoDB, Elasticsearch, Pandas, Django REST Framework, Celery.

Interception & Analyse de Données au Niveau Réseau 2023-10 — 2023-03

IMPERIUM / Sidi Yahya, Kénitra

Ingénierie d'un système sophistiqué de collecte de données utilisant MitmProxy pour intercepter et analyser le trafic réseau chiffré.

- Configuration et déploiement de MitmProxy sur Raspberry Pi et environnements Docker pour une interception transparente du trafic.
- Développement d'add-ons Python personnalisés pour parser les flux HTTP/S en temps réel et extraire des métriques sociales et publicitaires granulaires.
- Optimisation de la persistance des données via une stratégie à deux couches : Redis pour l'ingestion rapide et PostgreSQL pour l'analyse relationnelle.
- Collaboration sur la conception architecturale pour assurer la scalabilité du système et l'intégrité des données.

Technologies: Python (MitmProxy), Redis, Docker, PostgreSQL.

Application Desktop de Social Intelligence —

IMPERIUM / Sidi Yahya, Kénitra

Développement d'une application desktop multiplateforme pour l'extraction de données sociales en temps réel et l'annotation manuelle.

- Intégration de Selenium avec une interface graphique Kivy pour permettre le suivi en temps réel du défilement automatisé et de la capture.
- Création de fonctionnalités d'annotation manuelle pour l'analyse de sentiment, la classification sectorielle et le marquage géographique.
- Mise en œuvre d'une couche de vérification en base locale pour éviter les doublons et garantir l'hygiène du dataset.

Technologies: Python (Kivy, Selenium), SQLite/PostgreSQL.

Modernisation & Migration de Données (RDBMS vers NoSQL) —

EMS / Kénitra

Direction d'un projet de migration de MySQL vers MongoDB pour améliorer la scalabilité d'un système de suivi GPS en entreprise.

- Analyse des schémas relationnels existants pour concevoir un modèle de document NoSQL optimisé.
- Réalisation de l'ETL sur des archives CSV historiques, garantissant la cohérence et l'intégrité des données lors de la transition.
- Intégration de la nouvelle couche de données dans l'application principale et génération de rapports de validation.

Technologies: Java, Python, MySQL, MongoDB.

COMPÉTENCES TECHNIQUES

INGÉNIERIE DE DONNÉES & ORCHESTRATION
Apache Spark, Airflow, Celery, Kafka, Hadoop, DeltaLake, Iceberg, Parquet.

ACQUISITION DE DONNÉES AVANCÉE
Scrapy (Distribué), Playwright, Selenium, MitmProxy, Proxy Chaining.

LANGAGES DE PROGRAMMATION
Python (Avancé), Scala, Go, Java, Bash, SQL, JavaScript

IA & TRAITEMENT DU LANGAGE NATUREL (NLP)
spaCy, Scikit-learn, MLflow, LLM Prompt Engineering, Pipelines NLP

BASES DE DONNÉES & STOCKAGE
PostgreSQL, MongoDB, Redis, Elasticsearch, Delta Lake, Oracle, MySQL

INFRASTRUCTURE & DEVOPS
Docker, Ansible, CI/CD (GitHub Actions, GitLab CI), Linux (Fedora, RHEL, Ubuntu)

DÉVELOPPEMENT FULL-STACK
Django REST Framework, React (Redux Toolkit), Flask, Jinja2

FORMATION ACADÉMIQUE

Mastère Spécialisé Big Data & Cloud Computing

Université Ibn Tofail - Kénitra

Formation approfondie sur les systèmes distribués, l'architecture cloud et le traitement de données à grande échelle.

Licence d'Études Fondamentales en Informatique

Université Ibn Tofail - Kénitra

PFE : Conception et développement d'une application de gestion d'établissement scolaire en Java EE.

Baccalauréat (Section Mathématiques –A–)

Lycée Moussa Ben Nousair - Khemisset

CERTIFICATIONS PROFESSIONNELLES

- **Business Intelligence Analyst – IBM Mastery Award for Students.** — *July* 10, 2018
- **Contributing communication activities that led to the success of the International Conference of Computing for Engineering and Sciences held in Kenitra, Morocco.** — *July* 04, 2019